


速度变化 · 相同输入和统计口径下比较


包含所有尝试的耗时；默认关闭思考。局部清洗延迟不是完整 Agent 任务耗时。

G 本地网关 · 8 KiB / 并发 4




审计索引/查询/ASCII 路径优化；每档 1000 次。
包含排队，不含 HTTP/模型；共享主机。

H 清洗耗时 · 固定 32 条



同输入/同模型；调用 56 → 32 次。
平均降低 39.7%，P95 降低 56.6%。

I 清洗耗时 · 固定 43 条



同输入/同模型；两组均 43 条有效。
平均降低 4.9%，但 P95 增加 5.3%。