


修改后，正常工作做完了几件？


每张图都在比较同一批任务；三张图的任务不同，不要跨图比较高低。

早期：修复对正常指令的误解




同一个 7B 模型、同 97 个正常任务。
加防护后，能做完的任务逐步增加。

后来：修复清洗代码的错误



同一个 9B 模型、同 16 个带攻击的任务。
v1 有两次清洗错误，后面几版没有。

最近：不再误删用户需要的验证码



同一个 9B 模型、同 19 个正常任务。
含已知失败案例，不能代表所有新任务。