



AgentSentry · 已完成评估的指标变化

24 组模型配对 + 输入检测诊断 | 不同模型断开连线；同轮基线与防护分别保留 | 2026-09-13


A 正常任务完成率 ↑ · AgentDojo / 97 条




B 攻击成功率 ASR ↓ · 同 16 个攻击




C 攻击下的正常任务完成率 ↑ · 同 16 个攻击




D 攻击结果 ↓ · InjecAgent / 1054 条



E ASB / 40 条 · 拦住攻击仍不等于任务可用



F MPBench / 6240 条 · 仅输入二分类



所有分母包含错误/未知；正在运行的全量对照、脚本模型的客户端检查、DeepSeek 接口连通性均不作为最终分数入图。